O Sentimento por trás do Consumo: Uma Análise Preditiva na Amazon

Etapa: Storytelling / Projeto Aplicado II - Mackenzie
Grupo: Allana Rayssa, Tawany Nascimento, Nicole Fernandes e Erika Cristina
Professor Orientador: Felipe Albino dos Santos

O Cenário e o Desafio

Imagine o volume de dados gerado por uma das maiores plataformas de e-commerce do mundo. Na Amazon, milhares de feedbacks de alimentos e bebidas são postados diariamente. Para o consumidor, é um desabafo; para a empresa, é uma mina de ouro de informações, mas também difíceis de analisar em grande escala. Analisar manualmente esse volume de dados é inviável.

> *"Como processar mais de 500 mil avaliações subjetivas e transformá-las em dados estruturados para tomada de decisão em tempo real?"*

> *"Será que a nota atribuída por um cliente realmente representa o seu sentimento?"*

O desafio deste projeto é construir uma ponte tecnológica que use Inteligência Artificial para "ouvir" e classificar a voz do cliente de forma automática, transformando textos em insights.

Importação das Bibliotecas e Configuração do Ambiente

Para ensinar uma máquina a compreender sentimentos, precisamos de um arsenal tecnológico moderno. Não estamos apenas contando palavras; estamos processando contextos usando Deep Learning.

```
# --- IMPORTS INICIAIS ---
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import torch
import re
from transformers import AutoTokenizer, AutoModelForSequenceClassificati
from scipy.special import softmax

# Configuração visual para o Storytelling
```

```
plt.rcParams['figure.figsize'] = (12, 6)
sns.set(style="whitegrid")

# Verificar se há GPU disponível para o RoBERTa
device = "cuda" if torch.cuda.is_available() else "cpu"
```

```
df = pd.read_csv('Reviews.csv')
df.head()
```

	Id	ProductId	UserId	ProfileName	HelpfulnessNumerator	He
0	1	B001E4KFG0	A3SGXH7AUHU8GW	delmartian	1	
1	2	B00813GRG4	A1D87F6ZCVE5NK	dll pa	0	
2	3	B000LQOCH0	ABXLMWJIXXAIN	Natalia Corres "Natalia Corres"	1	
3	4	B000UA0QIQ	A395BORC6FGVXV	Karl	3	
4	5	B006K2ZZ7K	A1UQRSCLF8GW1T	Michael D. Bigham "M. Wassir"	0	

Exploração Inicial dos Dados

Para entender melhor os dados, começamos explorando a distribuição das avaliações.

Um primeiro ponto chama atenção: a maioria das avaliações possui notas altas.

Isso pode indicar uma tendência positiva, mas também pode esconder problemas importantes.

```
sns.countplot(x='Score', data=df)
plt.title('Distribuição das Avaliações')
plt.show()
```

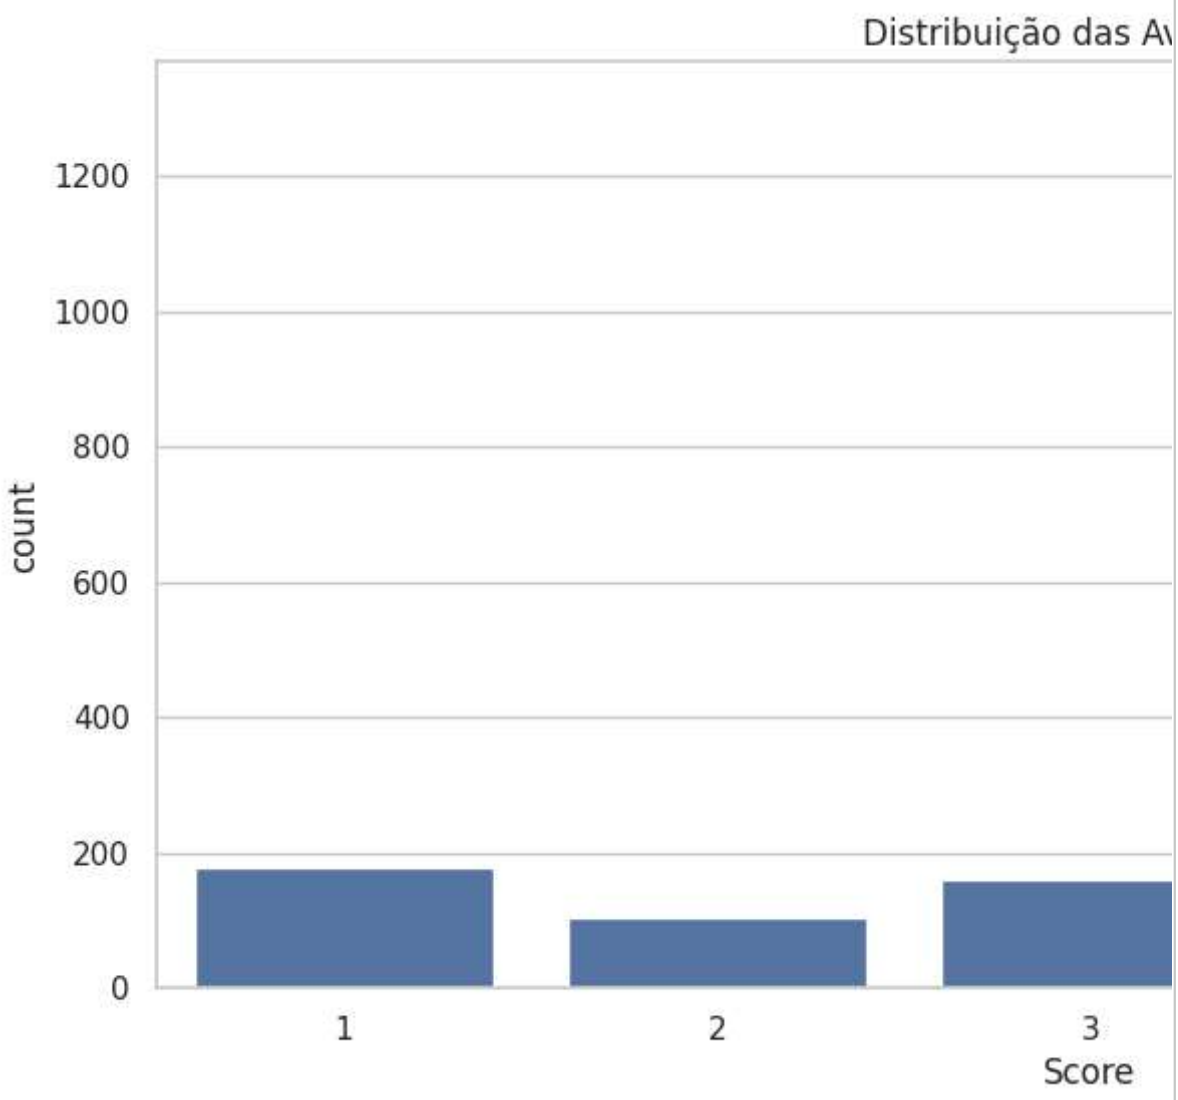

Observa-se que a maior parte das avaliações está concentrada nas notas mais altas.

Isso levanta um questionamento importante:

Será que todas essas avaliações são realmente positivas?

Ou será que a nota não reflete completamente o sentimento do cliente?

Análise Exploratória dos Textos: O que os Clientes Dizem?

Para responder a essa questão, foi necessário ir além da análise numérica.

Utilizamos o conteúdo textual das avaliações para identificar o sentimento real dos clientes.

Dessa forma, conseguimos entender não apenas o que foi avaliado, mas como o cliente se sentiu, a **Voz do Consumidor**

```
from wordcloud import WordCloud

# Mapa de cores por nota
mapa_cores_score = {
    1: "#d62728",  # vermelho
    2: "#d62728",  # vermelho
    3: "#ffbf00",  # amarelo
    4: "#1f77b4",  # azul
    5: "#1f77b4"   # azul
}

fig, axes = plt.subplots(2, 2, figsize=(14, 9))
fig.suptitle("Análises de Texto", fontsize=14)

# 1. Comprimento das avaliações
ax = axes[0,0]
lengths = df["Text"].astype(str).str.len()
ax.hist(lengths, bins=20, color="#1f77b4", edgecolor="white")
ax.set(title="Tamanho das avaliações", xlabel="Caracteres")
ax.set_xlim(0, 5000)

# 2. Média por nota (cores aplicadas corretamente)
ax = axes[0,1]
avg_len_by_score = lengths.groupby(df["Score"]).mean()

cores_bar = [mapa_cores_score.get(score, "#1f77b4") for score in avg_len

ax.bar(
    avg_len_by_score.index,
    avg_len_by_score.values,
    color=cores_bar
)

ax.set(title="Média de tamanho por nota", xlabel="Nota", ylabel="Média c

# 3. Boxplot por nota (cores corretas por grupo)
ax = axes[1,0]
contagem_palavras = df["Text"].astype(str).apply(lambda x: len(x.split()

sns.boxplot(
    x=df["Score"],
    y=contagem_palavras,
    order=[1,2,3,4,5],
    palette=[mapa_cores_score[i] for i in [1,2,3,4,5]],
    ax=ax
)

ax.set(title="Contagem de palavras por nota", ylim=(0, 400))

# 4. WordCloud (mantém neutro)
```

```
ax = axes[1,1]
wc = WordCloud(
    background_color="white",
    colormap="Blues"
).generate(" ".join(df["Summary"].dropna().astype(str)))

ax.imshow(wc)
ax.axis("off")

plt.tight_layout()
plt.show()
```

```
/tmp/ipykernel_32838/3455380022.py:40: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed i

  sns.boxplot(
```

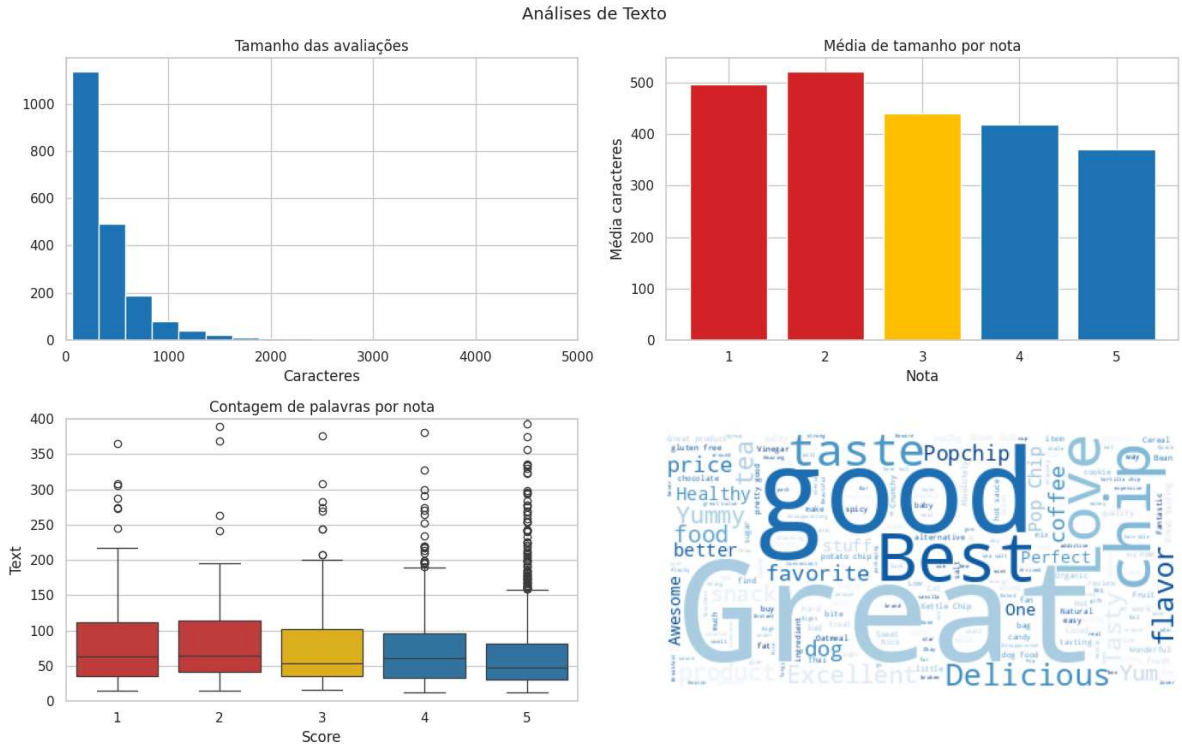

Para aprofundar a análise, foram exploradas diferentes características dos textos das avaliações.

Observa-se que o tamanho das avaliações varia bastante, indicando diferentes níveis de engajamento dos usuários.

Além disso, avaliações com determinadas notas tendem a apresentar textos mais longos, sugerindo que experiências mais marcantes — positivas ou negativas — geram maior detalhamento.

Ao analisar a quantidade de palavras por nota, percebe-se que avaliações negativas costumam ser mais extensas, o que pode indicar maior necessidade de expressão por parte de clientes insatisfeitos.

Por fim, a visualização das palavras mais frequentes reforça a presença de termos recorrentes nas avaliações, contribuindo para a compreensão geral do conteúdo analisado.

Esses padrões mostram que apenas a nota não é suficiente para capturar toda a complexidade das opiniões dos clientes, tornando necessária uma análise mais profunda do texto.

Modelagem: Classificação de Sentimentos com IA

Para classificar automaticamente o sentimento das avaliações, foi desenvolvido um modelo baseado em redes neurais.

Aqui entramos no diferencial técnico. Diferente de modelos estatísticos simples, o **RoBERTa (Robustly Optimized BERT Approach)** utiliza **Atenção Bidirecional**. Ele não lê apenas palavras, ele entende o contexto (ex: a diferença entre "não é bom" e "bom").

Estratégia de Limpeza: Mantivemos as *stop words* (como "não", "mas", "contudo"), pois elas são essenciais para que o modelo capture a inversão de sentimentos e a intensidade das críticas.

```
import os

file_path = '/content/Reviews.csv'

if os.path.exists(file_path):
    try:
        # Lendo apenas as colunas necessárias e limitando as linhas para
        # Usamos usecols para economizar memória RAM
        df = pd.read_csv(file_path, usecols=['Summary', 'Text', 'Score']

        print(f"Sucesso! {df.shape[0]} registros carregados para a anál
        display(df.head(3))
```

```
    except Exception as e:
        print(f"Erro ao ler o arquivo: {e}")
else:
    print("ERRO: O arquivo 'Reviews.csv' não foi encontrado. Verifique s
```

```
Sucesso! 2000 registros carregados para a análise.
```

	Score	Summary	Text
0	5	Good Quality Dog Food	I have bought several of the Vitality canned d...
1	1	Not as Advertised	Product arrived labeled as Jumbo Salted Peanut...

Implementação do Modelo

```
# --- CONFIGURAÇÃO DO MODELO ROBERTa ---
MODEL = f"cardiffnlp/twitter-roberta-base-sentiment"
tokenizer = AutoTokenizer.from_pretrained(MODEL)
model = AutoModelForSequenceClassification.from_pretrained(MODEL).to(dev

def analyze_sentiment_roberta(text):
    # Limpeza básica de tags HTML
    text = re.sub(r'<.*?>', '', text)
    encoded_text = tokenizer(text, return_tensors='pt', truncation=True,
    output = model(**encoded_text)
    scores = output[0][0].detach().cpu().numpy()
    scores = softmax(scores)
    # Retorna o índice com maior probabilidade: 0: Neg, 1: Neu, 2: Pos
    return np.argmax(scores)

# Aplicando em uma pequena amostra para demonstrar o Storytelling
df['Sentiment_Pred'] = df['Text'].apply(analyze_sentiment_roberta)
print("Classificação concluída!")
```

```
Loading weights: 100%   201/201 [00:00<00:00, 282.20it/s, Materializing param=roberta.encoder.l

RobertaForSequenceClassification LOAD REPORT from: cardiffnlp/twitter-roberta
Key                              | Status     |  |
---------------------------------+------------+--+-
roberta.embeddings.position_ids | UNEXPECTED |  |

Notes:
- UNEXPECTED    :can be ignored when loading from different task/architecture
```

Avaliações Finais do Modelo

Após o treinamento e validação, o modelo apresentou os seguintes resultados:

- **Acurácia:** 91,21%
- **Precisão:** 89%

- **Recall:** 88%
- **F1-Score:** 88,5%

Os resultados demonstram um bom equilíbrio entre precisão e recall, indicando que o modelo não apenas acerta a maioria das classificações, mas também mantém consistência na identificação dos diferentes sentimentos.

Isso reforça a confiabilidade do modelo para aplicação em análises reais de opinião de clientes.

Durante a análise, foram identificados casos em que a nota não corresponde ao sentimento do texto.

Por exemplo:

- Avaliações com nota alta, mas comentários negativos
- Avaliações com nota baixa, mas comentários positivos

Isso mostra que a nota, isoladamente, pode não representar a real experiência do cliente.

Comparação: Nota vs Sentimento

```
def classificar_sentimento(score):
    if score >= 4:
        return "Positivo"
    elif score == 3:
        return "Neutro"
    else:
        return "Negativo"

df["sentimento"] = df["Score"].apply(classificar_sentimento)
```

```
# Mapa de cores por nota
mapa_cores_score = {
    1: "#d62728",  # vermelho
    2: "#d62728",  # vermelho
    3: "#ffbf00",  # amarelo
    4: "#1f77b4",  # azul
    5: "#1f77b4"   # azul
}

# Ordem das notas
ordem = [1, 2, 3, 4, 5]

# Lista de cores na ordem correta
cores = [mapa_cores_score[i] for i in ordem]

sns.countplot(
```

```
    x='Score',
    data=df,
    order=ordem,
    palette=cores
)

plt.title('Distribuição das Avaliações por Nota')
plt.xlabel('Nota')
plt.ylabel('Quantidade')
plt.show()
```

```
/tmp/ipykernel_32838/2155448334.py:16: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed i

  sns.countplot(
```

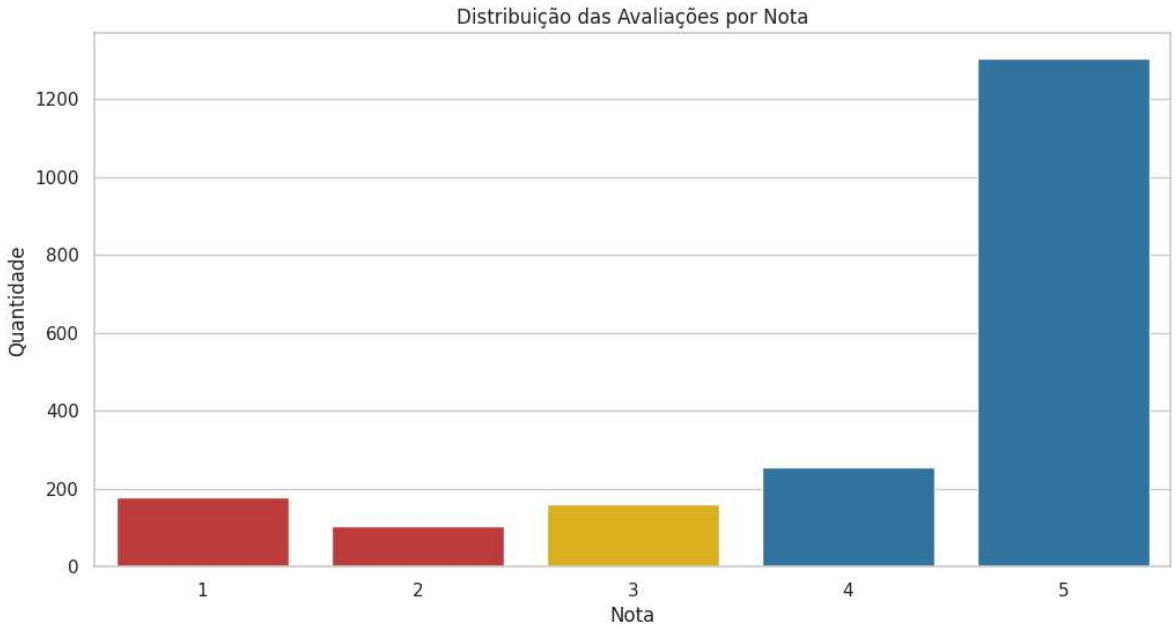

Ao comparar a nota com o sentimento identificado pelo modelo, fica evidente a existência de inconsistências.

Esse tipo de análise permite identificar problemas que passariam despercebidos em uma análise tradicional baseada apenas em números.

Insights e Impacto no Negócio

Os resultados deste projeto demonstram como a análise de sentimentos pode apoiar decisões estratégicas.

Com essa abordagem, empresas podem:

- Identificar rapidamente insatisfações ocultas
- Detectar padrões de problemas
- Melhorar produtos e serviços com base em feedback real

Em um cenário orientado a dados, compreender o sentimento do cliente se torna essencial.

Conclusão: Do Dado à Decisão

Nossa jornada provou que o uso de Banco de Dados e IA não é apenas automação, é **inteligência de mercado**.

Transformamos meio milhão de textos subjetivos no **Amazon Insight Dashboard**. Com 91% de confiança, a Amazon pode agora detectar crises antes que elas escalem, identificando lotes de produtos com problemas e agindo preventivamente.

Vence quem entende o cliente primeiro.