UNIVERSIDADE PRESBITERIANA MACKENZIE

CURSO – BANCO DE DADOS

PROJETO APLICADO II – ETAPA 1

PROFESSOR ORIENTADOR – FELIPE ALBINO DOS SANTOS

MODELO PREDITIVO PARA CLASSIFICAÇÃO DE AVALIAÇÕES DE CLIENTES DA AMAZON

Allana Rayssa Vieira de Oliveira – 10397812

Tawany Nascimento Santos -10746742

Nicole Fernandes Moreira - 10747302

Erika Cristina Alves Benesi Gomes - 10732522

São Paulo – SP

2026

1. APRESENTAÇÃO DA EMPRESA

O A Amazon é uma das maiores empresas de tecnologia e comércio eletrônico do mundo, fundada em 1994 por Jeff Bezos em Seattle, Washington (EUA). Com presença em dezenas de países, a Amazon opera em diversas áreas, incluindo marketplace (varejo online), computação em nuvem (AWS), streaming de conteúdo (Prime Video), inteligência artificial e logística.

No contexto deste projeto, o foco recai sobre o segmento de produtos alimentícios comercializados na plataforma Amazon por meio do programa Amazon Fine Foods. Esse segmento reúne avaliações textuais de clientes sobre alimentos e bebidas adquiridos no marketplace, acompanhadas de notas de 1 a 5 estrelas atribuídas pelos próprios consumidores. Para o nosso grupo de Banco de Dados, este dataset representa o desafio ideal de transformar textos subjetivos de clientes em dados estruturados para tomada de decisão.

A área de atuação escolhida é a de análise de sentimentos aplicada ao varejo digital. O problema de negócio que motiva o projeto é a necessidade de automatizar a classificação de avaliações de clientes — uma tarefa que, feita manualmente, seria inviável na escala de centenas de milhares de registros gerados pela plataforma.

2. GRUPO DE TRABALHO

O grupo é composto por quatro integrantes do curso de Banco de Dados da Universidade Presbiteriana Mackenzie. A divisão de responsabilidades da Etapa 1 foi feita conforme detalhado a seguir.

Integrante	Etapa 1 – Responsabilidade Principal	Tipo de Entrega
Tawany	Definição de objetivos e metas do projeto.	Texto acadêmico no Word
Erika	Identificação e carregamento do dataset no Colab.	Código Python (Colab) + explicação escrita no Word
Allana	Redação das premissas e contexto da organização	Texto acadêmico no Word

Integrante	Etapa 1 – Responsabilidade Principal	Tipo de Entrega
Nicole	Organização do cronograma e estrutura do GitHub	Documento Word final + repositório GitHub organizado

3. PREMISSAS DO PROJETO E PROBLEMA PREDITIVO

Nesta seção, estabelecemos o alicerce técnico do projeto, conectando a base de dados escolhida ao desafio de negócio da organização.

3.1 EMPRESA E ÁREA DE ATUAÇÃO

Organização Selecionada: Amazon Inc.
Segmento Específico: Mercado de alimentos e bebidas finas (Amazon Fine Foods).
Natureza dos Dados: O projeto processará dados não estruturados, especificamente avaliações textuais em língua inglesa.

3.2 O PROBLEMA PREDITIVO

Em vez de apenas classificar estrelas, o foco é a Análise de Sentimento. Nosso problema consiste em prever a polaridade da experiência do usuário com base exclusivamente no seu relato textual. Para viabilizar o treinamento do modelo, adotaremos a seguinte lógica de negócio:
Classe Positiva (1): Avaliações com Score 4 ou 5.
Classe Negativa (0): Avaliações com Score 1 ou 2.
Tratamento de Neutros: Registros com Score 3 serão removidos para reduzir ruídos na classificação binária, focando em sentimentos claros de satisfação ou insatisfação.

3.3 FERRAMENTAS E AMBIENTE TECNOLÓGICO

Para garantir a reprodutibilidade e o processamento eficiente dos ~568 mil registros, utilizaremos o ecossistema Python:
Ambiente: Google Colab para processamento em nuvem.
Stack Técnica: Pandas e Numpy para manipulação de dados; NLTK para o processamento de texto; e Scikit-Learn para a construção do modelo de Regressão Logística.
Versionamento: O controle de código e a documentação técnica serão centralizados em um repositório no GitHub

4. APRESENTAÇÃO DO DADOS – METADADOS

Nesta etapa, detalhamos a estrutura da base de dados utilizada, garantindo a rastreabilidade e a compreensão técnica das variáveis que alimentarão o modelo preditivo.

4.1 Fonte e Origem

- **Dataset:** Amazon Fine Food Reviews.
- **Procedência:** Grupo de pesquisa SNAP da Universidade de Stanford, via Kaggle.
- **Volume Total:** 568.454 registros coletados entre 1999 e 2012.
- **Amostragem de Desenvolvimento:** Para esta Etapa 1, trabalhamos com uma amostra controlada das primeiras 10.000 linhas, garantindo agilidade no processamento inicial e validação da estrutura.

4.2 Dicionário de Dados (Metadados)

Abaixo, apresentamos a tipagem técnica e a função estratégica de cada coluna conforme identificado em nossa análise exploratória via Python:

Coluna	**Tipo**	Descrição técnica	**Papel** no Projeto
ID	Int	Identificador único sequencial.	Controle interno/Indexação.
ProductId	Object	Código identificador do produto (ASIN).	Agrupamento de categorias.
UserId	Object	Identificador único do consumidor.	Feature auxiliar.
ProfileName	Object	Nome público do perfil do usuário.	Descarte (Privacidade/Irrelevante)

HelpfulnessNumerator	Int	Votos positivos de "utilidade" da review.	Métrica de relevância.
HelpfulnessDenominator	Int	Total de votos de utilidade recebidos.	Cálculo de taxa de confiança.
Score	Int	Nota de 1 a 5 atribuída pelo cliente.	Variável-Alvo (Target).
Time	Int	Timestamp Unix da postagem.	Análise temporal (opcional).
Summary	Object	Título ou resumo da avaliação.	Feature textual secundária.
Text	Object	Conteúdo integral da avaliação textual.	Feature Principal (NLP).

4.3 DIAGNÓSTICO DA AMOSTRA

- **Consumo de Memória:** A amostra de 10k linhas ocupa aproximadamente 781.4 KB, permitindo processamento rápido no ambiente Google Colab.

- **Integridade:** Não foram identificados valores nulos nas colunas críticas (Text e Score) nesta amostra inicial, o que reduz a necessidade de imputação de dados complexa na próxima fase.

5. OBJETIVOS E METAS

Esta seção descreve os resultados esperados para o projeto, alinhando a técnica de Aprendizado de Máquina (Machine Learning) com a necessidade de negócio da Amazon.

5.1 OBJETIVO GERAL

Desenvolver um modelo preditivo de aprendizado de máquina supervisionado para a classificação automática de avaliações de produtos alimentícios da Amazon. O modelo deve identificar se o texto escrito pelo usuário representa um sentimento positivo ou negativo, utilizando a técnica de Regressão Logística como abordagem principal.

5.2 OBJETIVOS ESPECÍFICOS

- **Análise Exploratória (EDA):** Identificar padrões na distribuição de notas e características textuais na base de dados *Amazon Fine Food Reviews*.

- **Pré-processamento Textual:** Estruturar um pipeline de limpeza que inclua normalização de texto, remoção de *stopwords* e vetorização via TF-IDF.
- **Treinamento do Modelo:** Implementar e treinar o algoritmo de Regressão Logística para a classificação binária de sentimentos.
- **Avaliação de Desempenho:** Mensurar a eficácia do modelo através de métricas de acurácia, precisão, *recall* e F1-score.

5.3 METAS E INDICADORES DE SUCESSO

Meta	Indicador de Sucesso
Coletar e carregar o dataset completo	Dataset disponível no repositório GitHub
Concluir análise exploratória (EDA)	Notebook Colab com gráficos: distribuição de scores, separação pos/neg, histograma de tamanhos e palavras frequentes
Executar pipeline de pré-processamento textual	Código funcional com limpeza, remoção de stopwords e vetorização TF-IDF documentados
Treinar modelo de regressão logística	Acurácia ≥ 80% no conjunto de teste
Entregar relatório e repositório finais	Entrega no Moodle e GitHub até o fim do semestre.

6. PENSAMENTO COMPUTACIONAL APLICADO

6.1 DECOMPOSIÇÃO

O problema foi decomposto nas seguintes etapas independentes, cada uma atribuída a uma integrante do grupo:

- Carregamento e inspeção inicial dos dados: estrutura, tipos, nulos e distribuição das notas (Tawany).
- Análise exploratória: gráficos de distribuição, separação positivo/negativo, histograma de tamanhos e palavras mais frequentes (Tawany).
- Pré-processamento e vetorização: limpeza textual, binarização do alvo, remoção de neutros e aplicação de TF-IDF (Erika).
- Fundamentação teórica: conceituação de ML supervisionado, classificação binária e regressão logística aplicada ao projeto (Allana).

- Avaliação do modelo: divisão treino/teste, métricas de desempenho e matriz de confusão (Nicole).
- Organização geral: montagem do documento Word, padronização e gestão do repositório GitHub (Nicole).

6.2 RECONHECIMENTO DE PADRÕES

Espera-se identificar os seguintes padrões nos dados:

- Avaliações com Score 4 ou 5 tendem a conter termos positivos como 'great', 'love', 'delicious', 'amazing', 'perfect'.
- Avaliações com Score 1 ou 2 tendem a apresentar termos negativos como 'terrible', 'waste', 'disgusting', 'bad', 'never again'.
- O comprimento do texto pode correlacionar-se com a polaridade da avaliação (reviews negativas tendem a ser mais longas).
- O índice de utilidade (HelpfulnessNumerator / HelpfulnessDenominator) pode ser um indicador da relevância da avaliação.

6.3 ABSTRAÇÃO

As variáveis relevantes para o modelo são:

- Feature principal de entrada: coluna Text (texto completo da avaliação), complementada por Summary.
- Variável-alvo binária: Score → 1 (Positivo: Score ≥ 4) | 0 (Negativo: Score ≤ 2). Registros com Score = 3 serão descartados.
- Feature auxiliar opcional: razão de utilidade (HelpfulnessNumerator / HelpfulnessDenominator), para eventuais análises de robustez.

6.4 ALGORITMO

1. Carregar dataset (Amazon Fine Food Reviews) no Google Colab.
2. Inspecionar shape, tipos de dados e valores nulos.
3. Análise exploratória: gráficos de distribuição de scores, separação positivo/negativo, histograma de comprimento dos textos e palavras mais frequentes.

4. Criar variável-alvo binária: Score ≥ 4 → Positivo (1); Score ≤ 2 → Negativo (0); Score = 3 → remover.

5. Pré-processar o texto: lowercase → remover HTML/pontuação → tokenizar → remover stopwords (NLTK).

6. Vetorizar com TF-IDF (unigrams + bigrams).

7. Dividir em treino (80%) e teste (20%) com estratificação por classe.

8. Treinar modelo de regressão logística.

9. Avaliar com acurácia, precisão, recall, F1-score e matriz de confusão.

10. Documentar resultados, gerar gráficos finais e publicar no GitHub.

7. CRONOGRAMA DE ATIVIDADES

7.1 CRONOGRAMA — Etapa 1 (Planejamento e Kick-off)

Atividade	Responsável	Prazo	Marco / Resultado
Formação do grupo e definição de papéis	Todo o grupo	Semana 1	Grupo formado e confirmado
Definição do tema, empresa e problema de pesquisa	Todo o grupo	Semana 1	Tema aprovado pelo grupo
Download e exploração inicial do dataset (Kaggle)	Allana	Semana 1	Dataset carregado e inspecionado
Criação das contas e repositório no GitHub	Nicole	Semana 1	Repositório público criado com estrutura de pastas
Redação do documento de entrega (Etapa 1)	Nicole	Semana 2	Documento formatado conforme padrão Mackenzie
Revisão e entrega final da Etapa 1	Todo o grupo	Semana 2	Documento enviado no Moodle

7.2 CRONOGRAMA COMPLETO DO PROJETO

Etapa / Atividade	Responsável	Prazo	Marco / Resultado Esperado
Etapa 1 – Planejamento e Kick-off	Todo o grupo	Semana 2	Documento entregue: contexto, objetivos, metadados, pensamento computacional, cronograma e link GitHub.
Download e organização do dataset	Allana	Semana 1	Dataset disponível no repositório.

Etapa / Atividade	Responsável	Prazo	Marco / Resultado Esperado
Criação do repositório GitHub e README	Nicole	Semana 1	Repositório documentado e organizado.
Documento de entrega Etapa 1	Nicole	Semana 2	Documento Word formatado e enviado.
Etapa 2 – Análise Exploratória de Dados (EDA)	Todo o grupo	Semana 6	Notebook EDA com estatísticas, gráficos e observações escritas.
Definição de linguagem e carregamento da base	Tawany	Semana 3	Notebook com estrutura do dataset documentada.
Gráficos: distribuição de scores, pos/neg, tamanho dos textos, palavras frequentes	Tawany	Semana 4	Gráficos gerados e salvos.
Observações escritas da análise exploratória	Tawany	Semana 4	Texto pronto para o Word.
Limpeza, transformação do alvo, tratamento textual e vetorização (TF-IDF)	Erika	Semana 5	Pipeline de pré-processamento funcional.
Texto explicativo do tratamento de dados	Erika	Semana 5	Explicação escrita pronta para o Word.
Base teórica: ML supervisionado, classificação, regressão logística e justificativa	Allana	Semana 5	Texto acadêmico com referências pronto para o Word.
Divisão treino/teste, métricas (acurácia, precisão, recall, F1, matriz de confusão)	Nicole	Semana 5	Texto explicativo pronto para o Word.
Montagem do documento final da Etapa 2 e atualização do GitHub	Nicole	Semana 6	Documento Word entregue + repositório atualizado.
Etapa 3 – Modelagem e Data Storytelling	Todo o grupo	Semana 10	Modelos treinados, avaliados e narrativa dos resultados.
Engenharia de features e treinamento de modelos	Allana + Erika	Semana 8	Modelos baseline (Regressão Logística + Naive Bayes) treinados.
Avaliação e seleção do melhor modelo	Allana + Erika	Semana 9	Métricas de desempenho documentadas.
Construção de gráficos finais e dashboards	Tawany	Semana 10	Visualizações para apresentação.

Etapa / Atividade	Responsável	Prazo	Marco / Resultado Esperado
Narrativa e síntese das descobertas	Nicole	Semana 10	Data storytelling pronto para revisão.
Etapa 4 – Apresentação e Entrega Final	Todo o grupo	25/05/2026	Relatório final, repositório atualizado e vídeo de apresentação.
Ajustes finais com base no feedback do professor	Todo o grupo	Semana 11	Documento revisado.
Gravação e edição do vídeo de apresentação	Todo o grupo	Semana 12	Vídeo revisado pelo grupo.
Entrega no Moodle e GitHub atualizado	Todo o grupo	25/05/2026	Projeto entregue oficialmente.

8. LINK PARA O REPOSITÓRIO DO GITHUB

https://github.com/nicolemoreira082-dot/projeto-aplicado-II

Obs.: Os arquivos do projeto (notebooks, dataset de amostra, gráficos e documentação) estão organizados conforme a estrutura descrita no README.md.

9. REFERÊNCIAS

MCAULEY, J.; LESKOVEC, J. From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews. In: Proceedings of the 22nd International Conference on World Wide Web (WWW), 2013. Disponível em: https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews. Acesso em: 2026.

GÉRON, A. Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow. 2. ed. Rio de Janeiro: Alta Books, 2021.

BIRD, S.; KLEIN, E.; LOPER, E. Natural Language Processing with Python. Sebastopol: O'Reilly Media, 2009. Disponível em: https://www.nltk.org/book/. Acesso em: 2026