UNIVERSIDADE PRESBITERIANA MACKENZIE

CURSO – BANCO DE DADOS

PROJETO APLICADO II – ETAPA 1

PROFESSOR ORIENTADOR – FELIPE ALBINO DOS SANTOS

MODELO PREDITIVO PARA CLASSIFICAÇÃO DE AVALIAÇÕES DE CLIENTES DA AMAZON

Allana Rayssa Vieira de Oliveira – 10397812

Tawany Nascimento Santos -10746742

Nicole Fernandes Moreira - 10747302

Erika Cristina Alves Benesi Gomes - 10732522

São Paulo – SP

2026

1. APRESENTAÇÃO DA EMPRESA

O A Amazon é uma das maiores empresas de tecnologia e comércio eletrônico do mundo, fundada em 1994 por Jeff Bezos em Seattle, Washington (EUA). Com presença em dezenas de países, a Amazon opera em diversas áreas, incluindo marketplace (varejo online), computação em nuvem (AWS), streaming de conteúdo (Prime Video), inteligência artificial e logística.

No contexto deste projeto, o foco recai sobre o segmento de produtos alimentícios comercializados na plataforma Amazon por meio do programa Amazon Fine Foods. Esse segmento reúne avaliações textuais de clientes sobre alimentos e bebidas adquiridos no marketplace, acompanhadas de notas de 1 a 5 estrelas atribuídas pelos próprios consumidores. Para o nosso grupo de Banco de Dados, este dataset representa o desafio ideal de transformar textos subjetivos de clientes em dados estruturados para tomada de decisão.

A área de atuação escolhida é a de análise de sentimentos aplicada ao varejo digital. O problema de negócio que motiva o projeto é a necessidade de automatizar a classificação de avaliações de clientes — uma tarefa que, feita manualmente, seria inviável na escala de centenas de milhares de registros gerados pela plataforma.

2. GRUPO DE TRABALHO

O grupo é composto por quatro integrantes do curso de Banco de Dados da Universidade Presbiteriana Mackenzie. A divisão de responsabilidades da Etapa 1 foi feita conforme detalhado a seguir.

Integrante	Etapa 1 – Responsabilidade Principal	Tipo de Entrega
Tawany	Definição de objetivos e metas do projeto.	Texto acadêmico no Word
Erika	Identificação e carregamento do dataset no Colab.	Código Python (Colab) + explicação escrita no Word
Allana	Redação das premissas e contexto da organização	Texto acadêmico no Word

Nicole	Organização do cronograma e estrutura do GitHub	Documento Word final + repositório GitHub organizado

3. PREMISSAS DO PROJETO E PROBLEMA PREDITIVO

Nesta seção, estabelecemos o alicerce técnico do projeto, conectando a base de dados escolhida ao desafio de negócio da organização.

3.1 EMPRESA E ÁREA DE ATUAÇÃO

Organização Selecionada: Amazon Inc.
Segmento Específico: Mercado de alimentos e bebidas finas (Amazon Fine Foods).
Natureza dos Dados: O projeto processará dados não estruturados, especificamente avaliações textuais em língua inglesa.

3.2 O PROBLEMA PREDITIVO

O problema central deste projeto consiste na classificação automatizada de sentimentos em avaliações textuais de clientes da Amazon. Diferente de uma abordagem estritamente binária, o modelo foi expandido para uma **classificação multiclasse**, permitindo a identificação de três estados emocionais: **Positivo, Neutro e Negativo**.
Para a rotulagem dos dados (labels), adotamos a seguinte lógica de negócio baseada no Score:
Classe Positiva (2): Avaliações com Score 4 ou 5.
Classe Neutra (1): Avaliações com Score 3 (mantidas para análise de nuances).
Classe Negativa (0): Avaliações com Score 1 ou 2.
O objetivo é prever a categoria correta com base no processamento de linguagem natural, utilizando modelos de Deep Learning.

3.3 FERRAMENTAS E AMBIENTE TECNOLÓGICO

Para garantir a reprodutibilidade e o processamento eficiente dos ~568 mil registros, utilizaremos o ecossistema Python:
Ambiente: Google Colab para processamento em nuvem.
Stack Técnica: Pandas e Numpy para manipulação de dados; NLTK para o processamento de texto; e Scikit-Learn para a construção do Modelo RoBERTa.

Versionamento: O controle de código e a documentação técnica serão centralizados em um repositório no GitHub

4. APRESENTAÇÃO DO DADOS – METADADOS

Nesta etapa, detalhamos a estrutura da base de dados utilizada, garantindo a rastreabilidade e a compreensão técnica das variáveis que alimentarão o modelo preditivo.

4.1 Fonte e Origem

- **Dataset:** Amazon Fine Food Reviews.
- **Procedência:** Grupo de pesquisa SNAP da Universidade de Stanford, via Kaggle.
- **Volume Total:** 568.454 registros coletados entre 1999 e 2012.
- **Amostragem de Desenvolvimento:** Para a execução final do projeto, optou-se pela utilização do **dataset completo**, processando o volume total de **568.454 registros**. Essa decisão visa garantir que o modelo RoBERTa seja validado em uma base de dados robusta, permitindo uma análise estatisticamente significativa da performance em larga escala.

4.2 Dicionário de Dados (Metadados)

Abaixo, apresentamos a tipagem técnica e a função estratégica de cada coluna conforme identificado em nossa análise exploratória via Python:

Coluna	Tipo	Descrição técnica	**Papel** no Projeto
ID	Int	Identificador único sequencial.	Controle interno/Indexação.
ProductId	Object	Código identificador do produto (ASIN).	Agrupamento de categorias.
UserId	Object	Identificador único do consumidor.	Feature auxiliar.
ProfileName	Object	Nome público do perfil do usuário.	Descarte (Privacidade/Irrelevante)
HelpfulnessNumerator	Int	Votos positivos de "utilidade" da review.	Métrica de relevância.
HelpfulnessDenominator	Int	Total de votos de utilidade recebidos.	Cálculo de taxa de confiança.

Score	Int	Nota de 1 a 5 atribuída pelo cliente.	Variável-Alvo (Target).
Time	Int	Timestamp Unix da postagem.	Análise temporal (opcional).
Summary	Object	Título ou resumo da avaliação.	Feature textual secundária.
Text	Object	Conteúdo integral da avaliação textual.	Feature Principal (NLP).

4.3 DIAGNÓSTICO DA AMOSTRA

- **Processamento em nuvem:** Dado o volume de ~568 mil registros, o processamento será realizado no ambiente **Google Colab com suporte a GPU**, utilizando bibliotecas otimizadas como Transformers e PyTorch para garantir a eficiência computacional no treinamento do modelo Deep Learning.

- **Integridade:** Não foram identificados valores nulos nas colunas críticas (Text e Score) nesta amostra inicial, o que reduz a necessidade de imputação de dados complexa na próxima fase.

5. OBJETIVOS E METAS

Esta seção descreve os resultados esperados para o projeto, alinhando a técnica de Aprendizado de Máquina (Machine Learning) com a necessidade de negócio da Amazon.

5.1 OBJETIVO GERAL

Desenvolver um modelo preditivo de aprendizado de máquina supervisionado para a classificação automática de avaliações de produtos alimentícios da Amazon. O modelo deve identificar se o texto escrito pelo usuário representa um sentimento positivo ou negativo, utilizando a técnica de Modelo RoBERTa como abordagem principal.

5.2 OBJETIVOS ESPECÍFICOS

- **Análise Exploratória (EDA):** Identificar padrões na distribuição de notas e características textuais na base de dados *Amazon Fine Food Reviews*.
- **Pré-processamento Textual:** Estruturar um pipeline de limpeza que inclua normalização de texto, remoção de *stopwords* e vetorização via TF-IDF.

- **Treinamento do Modelo:** Implementar e treinar o algoritmo do Modelo RoBERTa para a classificação binária de sentimentos.
- **Avaliação de Desempenho:** Mensurar a eficácia do modelo através de métricas de acurácia, precisão, *recall* e F1-score.

5.3 METAS E INDICADORES DE SUCESSO

Meta	Indicador de Sucesso
Coletar e carregar o dataset completo	Dataset disponível no repositório GitHub
Concluir análise exploratória (EDA)	Notebook Colab com gráficos: distribuição de scores, separação pos/neg, histograma de tamanhos e palavras frequentes
Executar pipeline de pré-processamento textual	Código funcional com limpeza, remoção de stopwords e vetorização TF-IDF documentados
Treinar o Modelo RoBERTa	Acurácia ≥ 80% no conjunto de teste
Entregar relatório e repositório finais	Entrega no Moodle e GitHub até o fim do semestre.

6. PENSAMENTO COMPUTACIONAL APLICADO

6.1 DECOMPOSIÇÃO

O problema foi decomposto nas seguintes etapas independentes, cada uma atribuída a uma integrante do grupo:

- Carregamento e inspeção inicial dos dados: estrutura, tipos, nulos e distribuição das notas (Tawany).
- Análise exploratória: gráficos de distribuição, separação positivo/negativo, histograma de tamanhos e palavras mais frequentes (Tawany).
- Pré-processamento e vetorização: impeza textual seletiva (preservando *stop words*) e conversão de texto para tensores compatíveis com a arquitetura RoBERTa (Erika).
- Fundamentação teórica: Conceituação de *Deep Learning*, arquitetura *Transformers* (RoBERTa) e análise de sentimento multiclasse aplicada ao projeto (Allana).
- Avaliação do modelo: Divisão treino/teste, análise de métricas multiclasse (acurácia, precisão, recall, F1-score) e matriz de confusão (Nicole).

- Organização geral: montagem do documento Word, padronização e gestão do repositório GitHub (Nicole).

6.2 RECONHECIMENTO DE PADRÕES

Espera-se identificar os seguintes padrões nos dados:

- Avaliações com Score 4 ou 5 tendem a conter termos positivos como 'great', 'love', 'delicious', 'amazing', 'perfect'.
- Avaliações com Score 1 ou 2 tendem a apresentar termos negativos como 'terrible', 'waste', 'disgusting', 'bad', 'never again'.
- O comprimento do texto pode correlacionar-se com a polaridade da avaliação (reviews negativas tendem a ser mais longas).
- O índice de utilidade (HelpfulnessNumerator / HelpfulnessDenominator) pode ser um indicador da relevância da avaliação.
- O modelo identifica que termos como "não" ou "mas" alteram completamente a polaridade de palavras positivas (ex: "não é bom"), reduzindo falsos positivos.
- Avaliações com Score 3 apresentam padrões linguísticos de ambiguidade ou satisfação parcial, que agora são classificados como "Neutros.

6.3 ABSTRAÇÃO

As variáveis relevantes para o modelo são:

- Feature principal de entrada: Colunas *Text* e *Summary* processadas integralmente (sem remoção de *stop words*).
- Variável-alvo multiclasse : Score 1 e 2 (Negativo | LABEL_0); Score 3 (Neutro | LABEL_1); Score 4 e 5 (Positivo | LABEL_2).
- Feature auxiliar opcional: razão de utilidade (HelpfulnessNumerator / HelpfulnessDenominator), para eventuais análises de robustez.

6.4 ALGORITMO

1. Carregar dataset completo (Amazon Fine Food Reviews) no Google Colab.
2. Inspecionar estrutura dos dados, tipos e presença de valores nulos ou duplicados.

3. Executar Análise Exploratória (EDA): distribuição de notas, volume por ano e métricas de texto.

4. Definir variável-alvo multiclasse: Score 4/5 (Positivo), Score 3 (Neutro) e Score 1/2 (Negativo).

5. Pré-processar o texto: Limpeza de tags HTML e caracteres especiais, mantendo as stop words para preservação de contexto.

6. Tokenização: Utilizar o tokenizer específico da arquitetura RoBERTa para converter palavras em tensores.

7. Carregamento de Modelo: Importar o modelo pré-treinado cardiffnlp/twitter-roberta-base-sentiment via Hugging Face.

8. Divisão e Treino: Separar dados em 80% treino e 20% teste com processamento em GPU.

9. Avaliação: Mensurar desempenho com Acurácia, Precisão, Recall, F1-Score e Matriz de Confusão.

10. Documentar resultados, gerar nuvem de palavras e publicar no GitHub.

7. CRONOGRAMA DE ATIVIDADES

7.1 CRONOGRAMA — Etapa 1 (Planejamento e Kick-off)

Atividade	Responsável	Prazo	Marco / Resultado
Formação do grupo e definição de papéis	Todo o grupo	Semana 1	Grupo formado e confirmado
Definição do tema, empresa e problema de pesquisa	Todo o grupo	Semana 1	Tema aprovado pelo grupo
Download e exploração inicial do dataset (Kaggle)	Allana	Semana 1	Dataset carregado e inspecionado
Criação das contas e repositório no GitHub	Nicole	Semana 1	Repositório público criado com estrutura de pastas
Redação do documento de entrega (Etapa 1)	Nicole	Semana 2	Documento formatado conforme padrão Mackenzie
Revisão e entrega final da Etapa 1	Todo o grupo	Semana 2	Documento enviado no Moodle

7.2 CRONOGRAMA COMPLETO DO PROJETO

Etapa / Atividade	Responsável	Prazo	Marco / Resultado Esperado
Etapa 1 – Planejamento e Kick-off	Todo o grupo	Semana 2	Documento entregue: contexto, objetivos, metadados, pensamento computacional, cronograma e link GitHub.
Download e organização do dataset	Allana	Semana 1	Dataset disponível no repositório.

Etapa / Atividade	Responsável	Prazo	Marco / Resultado Esperado
Criação do repositório GitHub e README	Nicole	Semana 1	Repositório documentado e organizado.
Documento de entrega Etapa 1	Nicole	Semana 2	Documento Word formatado e enviado.
Etapa 2 – Análise Exploratória de Dados (EDA)	Todo o grupo	Semana 6	Notebook EDA com estatísticas, gráficos e observações escritas.
Definição de linguagem e carregamento da base	Tawany	Semana 3	Notebook com estrutura do dataset documentada.
Gráficos: distribuição de scores, pos/neg, tamanho dos textos, palavras frequentes	Tawany	Semana 4	Gráficos gerados e salvos.
Observações escritas da análise exploratória	Tawany	Semana 4	Texto pronto para o Word.
Limpeza, transformação do alvo, tratamento textual e vetorização (TF-IDF)	Erika	Semana 5	Pipeline de pré-processamento funcional.
Texto explicativo do tratamento de dados	Erika	Semana 5	Explicação escrita pronta para o Word.
Base teórica: ML supervisionado, classificação, Modelo RoBERTa e justificativa	Allana	Semana 5	Texto acadêmico com referências pronto para o Word.

Divisão treino/teste, métricas (acurácia, precisão, recall, F1, matriz de confusão)	Nicole	Semana 5	Texto explicativo pronto para o Word.
Montagem do documento final da Etapa 2 e atualização do GitHub	Nicole	Semana 6	Documento Word entregue + repositório atualizado.
Etapa 3 – Modelagem e Data Storytelling	Todo o grupo	Semana 10	Modelos treinados, avaliados e narrativa dos resultados.
Engenharia de features e treinamento de modelos	Allana + Erika	Semana 8	Modelos baseline (Modelo RoBERTa+ Naive Bayes) treinados.
Avaliação e seleção do melhor modelo	Allana + Erika	Semana 9	Métricas de desempenho documentadas.
Construção de gráficos finais e dashboards	Tawany	Semana 10	Visualizações para apresentação.
Etapa / Atividade	**Responsável**	**Prazo**	**Marco / Resultado Esperado**
Narrativa e síntese das descobertas	Nicole	Semana 10	Data storytelling pronto para revisão.
Etapa 4 – Apresentação e Entrega Final	Todo o grupo	25/05/2026	Relatório final, repositório atualizado e vídeo de apresentação.
Ajustes finais com base no feedback do professor	Todo o grupo	Semana 11	Documento revisado.
Gravação e edição do vídeo de apresentação	Todo o grupo	Semana 12	Vídeo revisado pelo grupo.
Entrega no Moodle e GitHub atualizado	Todo o grupo	25/05/2026	Projeto entregue oficialmente.

8. FUNDAMENTAÇÃO TEÓRICA: DEEP LEARNING E TRANSFORMERS (RoBERTa)

*O projeto utiliza o RoBERTa (*Robustly Optimized BERT Approach*), um modelo de Aprendizado Profundo (*Deep Learning*) baseado na arquitetura* Transformers*. Este modelo é capaz de compreender o contexto bidirecional das frases, identificando gírias e variações linguísticas. Ao contrário de modelos estatísticos simples, o RoBERTa utiliza mecanismos de 'atenção' para entender a relação entre todas as palavras de um comentário simultaneamente."*

8.1 CLASSIFICAÇÃO MULTICLASSE E ANÁLISE DE SENTIMENTO

"A técnica aplicada é a classificação multiclasse, onde o modelo atribui probabilidades para as três categorias de sentimento. Através da biblioteca Hugging Face Transformers, o texto é processado para gerar um score de sentimento que é convertido em uma previsão de estrelas (1 a 5), permitindo comparar a percepção da IA com a nota real atribuída pelo usuário."

8.2 ESTRATÉGIA DE PRÉ-PROCESSAMENTO: MANUTENÇÃO DE CONTEXTO

"Uma decisão metodológica fundamental foi a manutenção das stop words (como 'não' e 'mas'). Modelos de Deep Learning necessitam da estrutura completa da frase para capturar a intensidade e a negação. O pipeline de limpeza foca na remoção de caracteres especiais e tags HTML, preservando a integridade gramatical necessária para a alta performance do modelo."

8.3 JUSTIFICATIVA DA ESCOLHA DO MODELO

*"A escolha do RoBERTa justifica-se por sua precisão superior em tarefas de NLP (*Natural Language Processing*). Sua capacidade de interpretar o contexto completo reduz drasticamente falsos positivos e negativos, garantindo que a meta de acurácia superior a 80% seja atingida com maior robustez técnica do que em métodos tradicionais.*

9. RESULTADOS E ANÁLISE DO MODELO

Aplicação do Método Analítico

Conforme definido na etapa anterior, foi utilizado o método de análise de sentimentos com apoio de técnicas de Processamento de Linguagem Natural (NLP), utilizando o modelo RoBERTa aplicado à base de dados Amazon Fine Food Reviews.

Inicialmente, os dados passaram por tratamento e limpeza, removendo informações inconsistentes e padronizando os textos. Em seguida, as avaliações foram classificadas conforme a nota atribuída pelo consumidor:

• Notas 1 e 2: sentimento negativo
• Nota 3: sentimento neutro
• Notas 4 e 5: sentimento positivo
Resultados Obtidos:

Acurácia: 91%
Precisão: 89%
Recall: 88%
F1-Score: 88,5%

● Tratamento e preparação dos dados: Não foram identificados valores nulos nas colunas principais (Text e Score), não sendo necessária a remoção de registros. Foram desconsideradas colunas não essenciais, como ProfileName e Time, visando otimizar o processamento e focar na análise textual.
● Análise exploratória (EDA): Observou-se predominância de avaliações positivas (notas 4 e 5), indicando desbalanceamento da base. Esse comportamento influencia o modelo, que tende a classificar mais avaliações como positivas.
● Aplicação do modelo RoBERTa: Utilização do modelo de Deep Learning para análise de sentimento, com interpretação contextual dos textos. Conversão dos resultados em escala de 1 a 5 estrelas para comparação com os valores reais.
● Desempenho na classificação multiclasse (1 a 5 estrelas): Melhor desempenho nas avaliações extremas (notas 1 e 5). Maior taxa de erro nas avaliações intermediárias (notas 2 e 3), devido à ambiguidade dos comentários. Limitação do modelo ao converter polaridade de sentimento em escala granular de notas.

● Análise por classificação binária: Exclusão das avaliações neutras (nota 3) para simplificação do problema. Agrupamento em duas classes: Negativo (notas 1 e 2) Positivo (notas 4 e 5)
● Resultados da classificação binária: Acurácia obtida: 91,21%. Alto desempenho na identificação de avaliações positivas. Maior dificuldade relativa na classificação de avaliações negativas, possivelmente devido ao desbalanceamento da base.
Após essa etapa, o modelo foi treinado para reconhecer padrões textuais e prever automaticamente o sentimento presente em novas avaliações.

Medidas de Acurácia

Para validar a eficiência do modelo proposto, foram utilizadas métricas amplamente reconhecidas em projetos de classificação supervisionada.

As métricas selecionadas foram:

• Acurácia: percentual total de classificações corretas
• Precisão: qualidade das previsões positivas
• Recall: capacidade de encontrar os casos corretos
• F1-Score: equilíbrio entre precisão e recall

Interpretação dos Resultados

Os resultados demonstram excelente desempenho do modelo. A acurácia de 91% indica alta capacidade de classificação correta das avaliações.

Observou-se melhor desempenho em avaliações claramente positivas ou negativas, enquanto avaliações neutras apresentaram maior complexidade, devido à ambiguidade natural da linguagem.

Mesmo assim, o modelo apresentou performance robusta e consistente, sendo adequado para aplicação prática em análise de opinião de clientes.

Conclusão dos resultados:

O modelo RoBERTa apresenta excelente desempenho na identificação de polaridade de sentimento**.** A simplificação para classificação binária aumenta significativamente a acurácia. A abordagem multiclasse (1 a 5 estrelas) é mais desafiadora e apresenta maior taxa de erro em avaliações intermediárias.

Projeto_Aplicado_II.ipynb

10. Storytelling

Vivemos em uma era em que consumidores compartilham opiniões a todo momento. Após cada compra, milhares de pessoas deixam comentários em plataformas digitais relatando suas experiências, expectativas atendidas, frustrações e recomendações.

Para o consumidor, trata-se apenas de uma avaliação. Para as empresas, porém, cada comentário representa uma oportunidade valiosa de aprendizado.

Dentro dessas mensagens estão escondidas respostas estratégicas para perguntas essenciais:

- O cliente está satisfeito?
- O produto atendeu às expectativas?
- Existem falhas recorrentes?
- O que precisa ser melhorado?
- Como fortalecer a reputação da marca?

O grande problema é que o volume dessas informações cresce em uma velocidade impossível de acompanhar manualmente. Empresas que recebem centenas ou milhares de avaliações por dia dificilmente conseguem ler, interpretar e agir sobre cada comentário em tempo hábil.

Como consequência, muitas organizações descobrem problemas tarde demais. Reclamações se acumulam, falhas operacionais se repetem e oportunidades de fidelização são desperdiçadas.

Foi justamente para resolver esse desafio que nasceu este projeto.

A proposta consiste em utilizar Inteligência Artificial para transformar milhares de textos dispersos em inteligência estratégica capaz de orientar decisões rápidas e assertivas.

Utilizando a base de dados Amazon Fine Food Reviews, composta por avaliações reais de consumidores, aplicamos técnicas modernas de Processamento de Linguagem Natural por meio do modelo RoBERTa, uma das arquiteturas mais avançadas para compreensão de linguagem humana.

O sistema foi treinado para identificar automaticamente o sentimento presente em cada comentário, classificando as avaliações em três categorias:

- Positivas
- Neutras
- Negativas

O que antes era apenas um grande volume de textos sem estrutura passou a se tornar informação clara, organizada e acionável.

Durante a análise, observou-se predominância de avaliações positivas, indicando boa aceitação de diversos produtos. Ao mesmo tempo, comentários negativos revelaram padrões importantes relacionados a atrasos na entrega, embalagens danificadas e inconsistências na qualidade percebida.

Esses achados mostram que, muitas vezes, os maiores problemas de uma empresa já estão sendo relatados pelos próprios clientes basta saber ouvir de forma inteligente.

Além disso, o modelo alcançou **91% de acurácia**, demonstrando elevada confiabilidade na identificação automática dos sentimentos. Isso significa transformar milhares de opiniões subjetivas em indicadores concretos, rápidos e escaláveis.

A partir desses resultados, foi idealizado um **Dashboard Inteligente de Sentimentos**, onde empresas poderão acompanhar em tempo real:

- Nível de satisfação dos clientes;
- Principais reclamações recorrentes;
- Tendência de reputação da marca;
- Produtos com melhor e pior desempenho;
- Alertas preventivos de crises.

Mais do que tecnologia, esta solução representa uma nova forma de gestão orientada por dados.

Em um mercado cada vez mais competitivo, vence quem entende o cliente antes da concorrência. E em um cenário onde cada comentário importa, saber interpretar a voz do consumidor deixa de ser diferencial e passa a ser necessidade estratégica.

Nosso projeto demonstra que, quando dados encontram inteligência artificial, opiniões se transformam em decisões, problemas se transformam em oportunidades e empresas se tornam mais preparadas para crescer de forma sustentável.

Data_Storytelling_PJII.ipynb

11. LINK PARA O REPOSITÓRIO DO GITHUB

https://github.com/nicolemoreira082-dot/projeto-aplicado-II

Obs.: Os arquivos do projeto (notebooks, dataset de amostra, gráficos e documentação) estão organizados conforme a estrutura descrita no README.md.

12. REFERÊNCIAS

MCAULEY, J.; LESKOVEC, J. From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews. In: Proceedings of the 22nd International Conference on World Wide Web (WWW), 2013. Disponível em: https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews. Acesso em: 2026.

GÉRON, A. Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow. 2. ed. Rio de Janeiro: Alta Books, 2021.

BIRD, S.; KLEIN, E.; LOPER, E. Natural Language Processing with Python. Sebastopol: O'Reilly Media, 2009. Disponível em: https://www.nltk.org/book/. Acesso em: 2026